

Informe Proyecto 1: LSA con SVD

En este proyecto realizamos un análisis latente usando SVD, donde se creó un repositorio llamado “[TMT2230-lgebra-Lineal-Avanzada-y-Modelamiento-Proyecto-1-LSA-con-SVD](#)”¹, que incluye principalmente la carpeta data con los datos necesarios, el enunciado del proyecto y un Jupyter Notebook llamado “main.ipynb” donde se desarrolla todo el proyecto (para verlo se necesita ejecutar este archivo), el cual, tiene las siguientes librerías como requerimiento para ejecutarlo correctamente: “pandas”, “os”, “re”, “nltk”, “sklearn”, “matplotlib”, “adjustText”, “numpy”, “pathlib” y “random”.

Para el proyecto se escogió el corpus extraído del dataset de Nikhil Nayak (llamado carlosgdcj en Kaggle) publicado en Kaggle como “[genius song lyrics with language information](#)”², que se trata de la recopilación de mas de 5 millones de canciones, poemas y libros, de todos los idiomas, estilos y épocas, de las cuales solo se usaran 500 escogidas al azar en español entre el primer millón de obras literarias, para que sea un numero

factible de procesar en cualquier dispositivo, para esto se filtraron primero todas las obras literarias a aquellas que solo estaban en español, y se usó “sample” con la semilla 23, para con ello tener muestras de obras de todos los estilos de forma aleatoria y que sea totalmente reproducible al siempre elegir la misma semilla. Después de extraer los 500 ejemplares, se creo un vector para analizar los términos totales y únicos de cada documento, y se guardo un archivo csv con las obras literarias que se usaran en el proyecto, ya que el archivo original, si bien se puede descargar perfectamente desde su fuente, al tener mas de 5 millones de documentos, no se puede subir al repositorio, por ende solo se subirán las obras que se usaran en el análisis.

Como hipótesis inicial se escogió esperar que con el análisis se pudiera clasificar cada obra literaria según su década al comparar el contenido de cada una de ellas, es decir, que se puede clasificar todos los de los años 80s por ejemplo en un grupo solo según las letras.

¹ Lyon Díaz, C. (2025). *Proyecto 1: LSA con SVD*. GitHub. <https://github.com/Cristobal-Lyon-Diaz/TMT2230-lgebra-Lineal-Avanzada-y-Modelamiento-Proyecto-1-LSA-con-SVD>

² CarlosGDCJ. (2023). *Genius Song Lyrics with Language Information*. Kaggle. <https://www.kaggle.com/datasets/carlosgdcj/genius-song-lyrics-with-language-information>

Para poder hacer un análisis correcto, fue necesario limpiar el texto de algunas cosas, primero se sacaron todos los caracteres que no eran alfanuméricos, como “!”, “\$”, “””, etc. Para aquello se realizó un ciclo for que dejaba cada texto en una lista con solo palabras (dejando aparte aquellas palabras con solo un carácter) que contenían únicamente caracteres alfanuméricos (se sacaron aquellos caracteres que no lo eran de cada palabra). Después se le aplico otro ciclo for para procesar cada palabra y dejarla en minúscula por completo y reemplazando aquellas vocales con tildes por vocales sin tildes para que no se diferencien palabras como “mas” y “más”, esto último haciendo una transición entre lista a dataframe para aplicarle el método map y devolverlo a lista. Posteriormente se eliminaron las stopwords en español obtenidas de “nltk”, las cuales también se le sacaron los tildes de la misma forma para no tener problemas, y se creó un vector TFIDF con las stop words (elimina aquellas), y que filtrara dejando solo aquellos términos que estén en mas de 5 documentos y menos del 90% de los documentos, para con ello revisar las palabras mas frecuentes del vector para ver si nos faltó algún termino por eliminar y con ello eliminarlos de la

misma manera, donde se decidió eliminar las palabras “tan”, “así”, “hace” y “cada” por tener nulo aporte y “verso”, “solo” y “coro” por pertenecer a la mayoría de las canciones que tenían solos, versos y coros (no eran parte de la verdadera letra).

Para definir la matriz A a usar, se traspuso la matriz X que nos otorgó el TFIDF, para seguir la convención del curso, ya que scikit-learn entrega una matriz con documentos en las filas y términos en las columnas, y lo que nosotros queremos es justo lo contrario, quedándonos una matriz real A de 1420 términos x 500 documentos. Donde además se explica que una entrada A sub ij en el contexto de TFIDF representa el peso del término i en el documento j, donde un valor alto significa que el termino i es frecuente en el documento j pero no en los demás documentos.

Para seguir con el análisis se descompuso la matriz en SVD con numpy, quedando en sigma un vector real de magnitud 500, representando los valores singulares, donde cada valor singular mide el peso de cada tema de las letras, U matriz real 1420 x 500 que tiene puras columnas ortonormales representan de que trata cada tema de las letras, y en VT matriz real 500x500 en

que cada fila representa en que canciones esta cada tema.

Para elegir la dimensión k se graficó el decrecimiento de los valores singulares para observar el punto de más diferencia de decrecimiento, siendo el valor 2, por ende se decidió $k=2$.

Después se creó un nuevo dataframe con los mismos datos, para poder manipular los años de cada obra literaria, los cuales se cambiaron a un string con sus décadas correspondientes (por ejemplo, una canción del año 1983 se cambió a “80s”) y junto ellos se usaron las funciones entregadas al canvas, en el archivo “[lsa_corpus_curso.html](https://cursos.canvas.uc.cl/courses/100248/files?preview=14720733)”³, y modificadas acorde al código propio en el notebook (que agrupe por décadas en vez de por semanas y asignarles colores), para con ellas graficar los componentes 2 vs 3 (se escogieron estos y no 1 y 2 ya que la diferencia entre ellos era más del doble, haciendo 2 y 3 una mucha mejor comparación) y determinar que palabras son las que influyen más en cierta década y si se agrupan los documentos visualmente por sus respectivas décadas. Lamentablemente al observar los resultados se puede apreciar que al menos de manera visual en el plano en

2D no se agrupan por décadas, pero a su vez se logro rescatar que las palabras “amor” y “quiero” estaban presentes en varios documentos, significando un gran peso en la toma de decisiones y que probablemente gran parte de las obras literarias se traten de temas afectivos.

Para la exploración semántica, ya que se definió previamente el uso de $k=2$, se crearon matrices U_k (todas las filas pero las columnas hasta la k) significando las direcciones principales de los términos a los valores singulares correspondientes, s_k (los primeros k elementos del vector) significando los k primeros valores singulares, V_k (las primeras k filas con todas sus columnas) significando las direcciones principales de los documentos, T_k (el producto de U_k y s_k) significando las coordenadas de cada termino en un plano de k dimensiones y D_k (el producto transpuesto de la matriz expandida del vector s_k y V_k) significando las coordenadas de los documentos en un plano de dimensión k .

En la exploración semántica se realizaron dos ejemplos, el primero viendo la similitud de las palabras con 3 palabras cotidianas (“amor”, “noche” y “luna”), donde todos los resultados

³ **Urrutia F.** (2025). *SVD en ejemplos y LSA con los apuntes del curso*. IMT2230 Álgebra Lineal Avanzada y Modelamiento. Canvas UC. <https://cursos.canvas.uc.cl/courses/100248/files?preview=14720733>

fueron nada coherentes, ya que a pesar de que en amor lo asimilan a “podre”, “regresa”, “adios”, “querido”, marchó y lloro, palabras que estoy en demasiado acuerdo su similitud, al otro lado, con luna y noche erro completamente, ya que ninguna de sus palabras (o como máximo 2 de ellas) se asemeja a la palabra original, por lo tanto en este ejemplo, no sirve para defender nuestra hipótesis.

El otro ejemplo que se elaboró, y el que mas posibilidades tiene de defender la hipótesis, consiste en comparar la similitud de los documentos para ver si se asemejan según las décadas poniendo 3 documentos al azar (con una semilla random para poder hacer reproducible el ejemplo), donde se puede apreciar que solo acertó en un 7% de los documentos, por lo tanto definitivamente no funciona este ejemplo, y no se pudo defender la hipótesis con él.

Al final del análisis, con todo el desarrollo hecho, podemos llegar a la conclusión que la hipótesis es falsa, y al menos con un análisis de LSA con SVD no se pueden clasificar obras líricas por décadas según el contenido de sus palabras, esto debido al fracaso del grafico de la pregunta 7, donde no se agrupan los documentos por décadas al comparar sus componentes, además del fracaso rotundo en los dos ejemplos

finales, por ende la hipótesis resulto ser falsas. Unas de las limitaciones que tiene, es que no se pudieron usar los 5 millones de datos completos por la gran cantidad de recursos que ocuparía, teniendo que usar solo 500, haciendo menos exacta la predicción.